

基于 Kmeans-SVM 的短期光伏发电功率预测

张雨金, 杨凌帆, 葛双冶, 周杭霞

(中国计量大学信息工程学院, 浙江 杭州 310018)

摘要: 短期光伏发电功率预测对维护电网安全稳定和协调资源利用具有重要的意义。提出了一种基于 K 均值算法(Kmeans)和支持向量机(SVM)的短期光伏发电功率预测方法。根据短期光伏发电特性和光伏发电季节特性, 组织预测模型的训练样本集。通过 K 均值算法对训练样本集进行聚类分析, 在聚类得到的各类别数据上分别训练支持向量机。预测时根据预测样本的类别使用相应的支持向量机进行发电功率预测。经实验表明所提出的方法相较于传统的 BP、SVM 模型精度有了明显的提升, 具有较好的工程应用潜力。

关键词: 光伏发电; 预测模型; 特性分析; K 均值算法; 支持向量机

Short-term photovoltaic power forecasting based on Kmeans algorithm and support vector machine

ZHANG Yujin, YANG Lingfan, GE Shuangye, ZHOU Hangxia

(College of Information Engineering, China Jiliang University, Hangzhou 310018, China)

Abstract: Short-term photovoltaic power forecasting is of great significance for maintaining the security and stability of the power grid and coordinating the utilization of resources. In this paper, a short-term photovoltaic power generation prediction method based on Kmeans algorithm and Support Vector Machine (SVM) is proposed. According to short-term photovoltaic power generation characteristics and seasonal characteristics, the training set of the prediction model is organized. The Kmeans algorithm is used to cluster the training set. Each class of data obtained by clustering is used to train a SVM. The SVM of the same type is used as the forecast sample for power generation prediction. Experiments show that the prediction accuracy of the proposed model is better than that of the traditional BP model and SVM model, so it has a good engineering application value.

This work is supported by Basic Public Benefit Research Program of Zhejiang Province (No. LGF18F020017).

Key words: PV power generation; prediction model; characteristic analysis; Kmeans algorithm; SVM

0 引言

光伏发电受太阳辐照度、环境温湿度、通风条件等因素的影响, 不同天气, 不同时段的发电量差异巨大。光伏发电具有随机性、波动性和间歇性的特点, 当大规模的光伏系统并网后会对电网的稳定性和安全性造成冲击^[1-3]。为了减少光伏发电对电网的影响、提高资源利用率、平衡电力市场供需, 就需要对电网进行合理调度。对光伏发电功率进行预测可作为电网调度和电站维护的参考^[4-5], 有利于维护电网安全稳定和光伏电站经济运营。

短期光伏发电预测可用于光伏出力平滑控制和电网的调度。目前国内外学界对光伏发电预测已有了一定的研究。气象预测法以天气预报系统预测的

气象参数作为预测模型输入量, 来预测光伏发电量^[6-8]。文献[9]在克里格模型的基础上结合太阳辐射强度预测模型, 实现光伏发电量预测。相似日法通过太阳辐照度、时间、温度、相对湿度等参数, 从历史数据中选取与当前气象条件相似的数据, 以相似日数据训练模型来进行预测^[10-12]。机器学习法为精准分析光伏发电影响因素和提高光伏发电功率预测精度提供了有效途径, 该方法使用神经网络算法^[13-14]和支持向量机(SVM)^[15-16]较多, 已有多种基于这两个算法的改进模型被提出^[17-18], 机器学习法晴天预测误差在 8% 左右^[19], 多云误差约为 26.20%, 阴雨天误差约为 43.05%^[20]。

上述研究中, 气象预测法受到目前天气预报系统精度的限制, 预测的气象参数的误差较大时, 就会严重影响模型的预测精度。相似日法将晴转多云、多云转雨等复杂天气类型归类到晴天、雨天、多云

基金项目: 浙江省基础公益研究计划项目(LGF18F020017)

等少数几个简单天气类别中, 在晴转多云、多云转雨等复杂气象条件下进行预测时误差较大。机器学习法使用 BP 神经网络面临着易于陷入局部最优和迭代收敛慢的问题, 该方法在雨天的预测性能欠佳, 存在一定的改进空间。

本文提出了一种基于 Kmeans 和 SVM 的短期光伏发电功率预测方法, 在短期光伏发电特性分析与光伏发电季节特性分析的基础上组织模型的训练样本集; 利用 Kmeans 算法对训练样本进行聚类分析, 将训练样本分为 K 个样本子集; 针对不同类别的样本子集训练 SVM; 预测时选用与预测样本同类别的 SVM 进行预测。本文基于实测数据进行算例分析, 考察本文方法在稳定气象条件与突变气象条件下的预测效果, 并与传统方法进行对比, 体现本文方法的优势。

1 算法简述

1.1 Kmeans 算法

Kmeans 算法是常用的一种聚类算法^[21-22], 该算法采用距离来衡量样本之间的相似性, 能将样本集划分成 K 个簇, 簇 C_i 的均值向量

$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x \quad (1)$$

为该簇的质心。Kmeans 算法的目的就是寻找 K 个质心来最小化平方误差。

$$E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|_2^2 \quad (2)$$

平方误差 E 越小则表明簇内样本的相似度越高。Kmeans 算法的主要过程如下。

输入: 样本集 $\text{dataset} = \{X_1, X_2, \dots, X_n\}$, K 值

输出: 簇集 $\text{clusterset} = \{C_1, C_2, \dots, C_K\}$

从样本集中随机选择 K 个样本 $\{\mu_1, \mu_2, \dots, \mu_K\}$ 作为初始质心。

repeat

for $i=1, 2, \dots, n$ do

for $j=1, 2, \dots, k$ do

计算样本 X_i 与质心 μ_j 之间的距离

distance = $\|X_i - \mu_j\|_2$;

end for

将样本 X_i 与它最近的质心 μ 归为一类;

end for

for $j=1, 2, \dots, k$ do

更新质心: $\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$;

end for

until 达到最大迭代次数或质心更新幅度小于阈值。

1.2 SVM 算法

SVM 算法在 1995 年由 Vapnik 等人提出^[23], 该算法以统计学习理论为基础, 结合结构风险最小化理论, 可以解决小样本、非线性、高维数等问题, 目前已成功应用到诸多领域^[24-25]。给定样本集 $\text{dataset} = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 其中 $x_i \in R^d$ 是输入值, $y_i \in R$ 是目标值, $i=1, 2, \dots, n$, 通过线性回归函数

$$f(x) = w^T x + b \quad (3)$$

来拟合样本 (x_i, y_i) , 采用 ε 不敏感损失函数

$$|y - f(x)|_\varepsilon = \begin{cases} 0 & |y - f(x)| \leq \varepsilon \\ |y - f(x)| - \varepsilon & |y - f(x)| > \varepsilon \end{cases} \quad (4)$$

引入惩罚因子 C 和松弛因子 ξ_i 、 ξ_i^* , 则最优化问题为

$$\min \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \quad (5)$$

$$\text{s.t. } f(x_i) - y_i \leq \varepsilon + \xi_i,$$

$$y_i - f(x_i) \leq \varepsilon + \xi_i^*,$$

$$\xi_i \geq 0, \xi_i^* \geq 0, i=1, 2, \dots, n$$

引入拉格朗日乘子 α_i 、 α_i^* 、 μ_i 、 μ_i^* 得到最优化问题的拉格朗日函数为

$$L = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) - \sum_{i=1}^n \mu_i \xi_i - \sum_{i=1}^n \mu_i^* \xi_i^* + \sum_{i=1}^n \alpha_i (f(x_i) - y_i - \varepsilon - \xi_i) + \sum_{i=1}^n \alpha_i^* (y_i - f(x_i) - \varepsilon - \xi_i^*) \quad (6)$$

将 L 分别对 w 、 b 、 ξ_i 和 ξ_i^* 求偏导, 使各偏导为 0 可以得到

$$w = \sum_{i=1}^n (\alpha_i^* - \alpha_i) x_i \quad (7)$$

$$0 = \sum_{i=1}^n (\alpha_i^* - \alpha_i) \quad (8)$$

$$C = \alpha_i + \mu_i \quad (9)$$

$$C = \alpha_i^* + \mu_i^* \quad (10)$$

将上述 4 式代入式(6), 可以得到式(5)的对偶问题。

$$\max_{\alpha, \alpha^*} \sum_{i=1}^n y_i (\alpha_i^* - \alpha_i) - \varepsilon (\alpha_i^* + \alpha_i) - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n (\alpha_i^* - \alpha_i) (\alpha_j^* - \alpha_j) x_i^T x_j \quad (11)$$

$$\text{s.t. } \sum_{i=1}^n (\alpha_i^* - \alpha_i) = 0,$$

$$0 \leq \alpha_i, \alpha_i^* \leq C$$

将式(7)代入式(3)得到回归模型, 如式(12)。

$$f(x) = \sum_{i=1}^n (\alpha_i^* - \alpha_i) x_i^T x + b \quad (12)$$

若使用核函数 $k(x, x_i)$ 代替内积计算, 则回归模型可表示为

$$f(x) = \sum_{i=1}^n (\alpha_i^* - \alpha_i) k(x, x_i) + b \quad (13)$$

2 预测模型构建

2.1 光伏发电特性分析

光伏发电受天气、环境等因素影响具有随机性和波动性, 尤其在多云、阴雨的气象条件下, 一天的光伏发电功率曲线剧烈波动, 产生多个峰值, 选取晴天、雨天、多云三种天气的发电功率曲线如图1所示。若将时间粒度由一天缩短到十几分钟, 在这短时间内天气、环境等因素虽有变化, 却不容易引起发电功率的剧烈波动, 如图2所示, 在短时间内, 相邻几个时刻的光伏发电数据波动较小, 具有一定的相关性。



图1 全天光伏发电功率

Fig. 1 Full day PV power curve




图2 短时光伏发电功率

Fig. 2 Short time PV power curve

季节差异会对光伏发电产生明显的影响, 这是因为每个季节的辐射强度、光照时长、环境温度都有着明显的差别, 不同地理位置的季节差异也不同。浙江绍兴地区4个季节晴天的发电功率曲线如图3所示, 发电功率曲线的峰值、发电起止时间都不同。




图3 不同季节晴天光伏发电功率

Fig. 3 PV power curve on sunny days in different seasons

由上述分析可知, 光伏系统在短期内波动较小, 具有一定的相关性, 可以根据近期相邻时刻的发电数据来预测下一时刻的发电功率。不同季节对光伏发电有较大的影响, 因此选用与预测样本相同月份和该月份前一月与后一月, 共3个月份的历史数据来训练预测模型, 以降低季节变化对模型预测精度的影响。

2.2 预测模型构建

Kmeans-SVM 预测模型框架如图4所示。光伏组件输出的直流电流 I 、直流电压 V 、组件温度 T 、发电功率 P 可以很好地表示当前光伏发电状态。该预测模型将当前时刻 t 和 t 时刻的 $I(t)$, $V(t)$, $T(t)$,

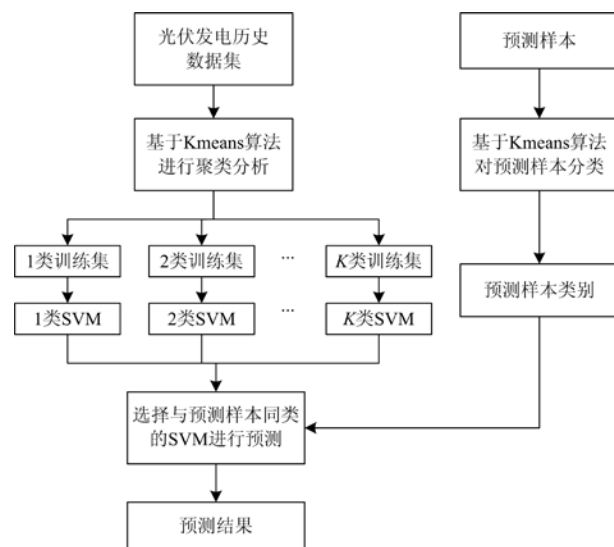


图4 Kmeans-SVM 预测模型框架

Fig. 4 Kmeans-SVM prediction model framework

$P(t)$, t 时刻上一时刻的 $I(t-1)$, $V(t-1)$, $T(t-1)$, $P(t-1)$ 作为训练样本的特征, t 时刻下一时刻的发电功率 $P(t+1)$ 作为训练样本的目标, t 时刻的训练样本可表示为

$$\text{sample} = [(t, I(t), V(t), T(t), P(t), I(t-1), V(t-1), T(t-1), P(t-1)), P(t+1)] \quad (14)$$

该预测模型可表示为

$$P(t+1) = \text{model}(t, I(t), V(t), T(t), P(t), I(t-1), V(t-1), T(t-1), P(t-1)) \quad (15)$$

以连续两个时刻的 I 、 V 、 T 、 P 作为样本特征, 使 Kmeans 算法可以把连续两个时刻光伏发电状态相近的样本归为一类, 以时刻 t 为特征可使归为一类的样本尽量在相邻时段。该模型先基于 Kmeans 算法对样本集进行聚类分析, 将样本集分成 K 个训练集, 此处的 K 值通过经验法、试凑法确定, 使用与预测样本同类的训练样本训练的 SVM 来预测下一时刻的发电功率。

2.3 数据归一化处理与模型评价指标

训练样本包含时刻、电流、电压、温度和发电功率五种参数, 这些参数单位不同, 数量级也相差甚远, 因此需要进行归一化处理, 本文采用如式(16)的归一化方法。

$$x_i^* = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (16)$$

式中: x_i 为原始输入数据; x_i^* 为归一化后的数据。一个训练样本归一化实例如表 1 所示, 该训练样本以当前时刻(按秒计算)、9:31:05 和 9:23:05 两个时刻的直流电流电压、组件温度、发电功率为样本特征, 以 9:39:05 的发电功率为训练目标, 按照式(16)进行归一化处理。

表 1 训练样本归一化实例

Table 1 Example of the normalization of a training sample

	时刻点/单位	原始数据	归一化数据
样本特征	$t(9:31:05)/s$	34 265	0.396 585 648
	$I(9:31:05)/A$	3.2	0.157 360 406
	$V(9:31:05)/V$	616.3	0.785 189 847
	$T(9:31:05)/^{\circ}C$	54.9	0.835 214 447
	$P(9:31:05)/W$	3 965	0.199 778 304
	$I(9:23:05)/A$	2.1	0.101 522 843
	$V(9:23:05)/V$	600.3	0.751 625 76
训练目标	$T(9:23:05)/^{\circ}C$	55.3	0.844 243 792
	$P(9:23:05)/W$	2 447	0.123 293 193
	$p(9:39:05)/W$	5 829	0.293 696 78

本文采用平均绝对百分比误差 MAPE 和拟合优度 R^2 来评价模型的预测能力。

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \frac{|x_{\text{model},i} - x_{\text{actual},i}|}{x_{\text{actual},i}} \quad (17)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (x_{\text{model},i} - x_{\text{actual},i})^2}{\sum_{i=1}^n (x_{\text{actual},i} - \bar{x})^2} \quad (18)$$

式中: x_{model} 为模型预测值; x_{actual} 为实际值。

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_{\text{actual},i} \quad (19)$$

3 算例分析

本文数据为浙江绍兴地区某 20 kW 小型光伏电站监控数据, 该监控数据从光伏系统接受光照自动开始发电到自动停止发电期间, 每隔 8 min 记录当前时刻 t 、光伏组件输出直流电 I 、直流电压 V 、组件温度 T 、当前发电功率 P 。本文选用 2015 年 4 月—6 月和 2016 年 4 月的数据来训练预测模型, 考察该模型在 2016 年 5 月的晴天、雨天、多云三种气象条件下的表现。为考察本文提出的 Kmeans-SVM 预测模型在精度方面的表现, 采用 BP 模型、Kmeans-BP 模型、SVM 模型与本文模型进行对比, 通过试凑法确定 K 值为 9, SVM 采用 Linear 核函数。

四种模型在晴天的预测结果如图 5 所示。晴天的光照、温度、湿度等气象条件不会频繁波动, 因此光伏发电功率波动较小, 四种模型在上午和下午的预测值都很贴近实测值, 但在中午 BP 模型和 Kmeans-BP 模型出现了较大的误差, SVM 模型和 Kmeans-SVM 模型则表现较好。

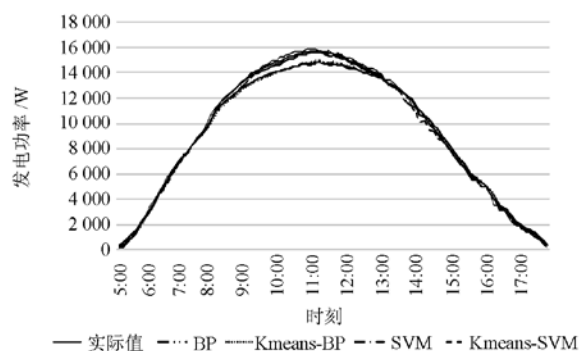


图 5 四种模型在晴天的发电功率预测曲线

Fig. 5 Prediction curves of four models in sunny day

四种模型在雨天的预测结果如图 6 所示。雨天的光照、气温、湿度等气象条件变化剧烈, 使得某些时段的预测误差较大, 很难做出精准预测。本文

提出的 Kmeans-SVM 预测模型可较好地预测光伏发电功率的变化趋势。




图 6 四种模型在雨天的发电功率预测曲线

Fig. 6 Prediction curves of four models in rainy day

四种模型在多云情况下的预测结果如图 7 所示。受风力的作用，云层的厚度及位置在不断变动，光伏组件接收到的太阳辐射在随机波动，这使得预测结果误差较大。本文提出的 Kmeans-SVM 预测模型在预测误差上优于其他 3 个模型。




图 7 四种模型在多云天气的发电功率预测曲线

Fig. 7 Prediction curves of four models in cloudy day

四种模型在晴天、雨天、多云气象条件下预测的平均绝对百分比误差 MAPE 值如表 2 所示。

表 2 四种模型平均绝对百分比误差

Table 2 MAPE of four models

	BP	Kmeans-BP	SVM	Kmeans-SVM
晴天	8.99	7.12	5.75	4.82
雨天	44.52	32.22	35.54	30.06
多云	23.64	22.60	20.58	19.99

四种模型在晴天、雨天、多云气象条件下预测的拟合优度 R^2 值如表 3 所示。

由表 2 可以看出本文提出的 Kmeans-SVM 模型在晴天、雨天、多云的 MAPE 值均低于其他 3 种预

测模型。由表 3 可以看出 Kmeans-SVM 模型在多云下的拟合优度略低，在晴天、雨天的拟合优度高于其他三种预测模型。由表 2 和表 3 中 BP 模型和 Kmeans-BP 模型进行对比，SVM 模型和 Kmeans-SVM 模型进行对比，可以看出加入 Kmeans 算法对训练数据进行聚类分析后，模型的预测精度和拟合优度均有了明显的提升。

表 3 四种模型拟合优度表

Table 3 R^2 of four models

	BP	Kmeans-BP	SVM	Kmeans-SVM
晴天	0.988 6	0.988 9	0.998 5	0.996 5
雨天	0.851 8	0.857 6	0.860 4	0.862 8
多云	0.791 8	0.791 8	0.777 8	0.781 5

综上所述，本文的 Kmeans-SVM 预测模型相比于传统的预测模型，具有更高的预测精度和拟合优度，可以在短期内很好地预测光伏发电功率。

4 结语

进行光伏发电预测对协调资源利用、维护电网安全稳定具有重要意义。本文基于光伏电站实测数据分析了短期光伏发电的特性和光伏发电的季节特性，提出一种基于 Kmeans-SVM 的预测模型。

1) 该模型以当前时刻和最近连续两个时刻的组件温度、直流电流电压、发电功率为输入，来预测下一时刻的发电功率。

2) 该模型无需考虑数据的天气类别，采用 Kmeans 算法对训练样本进行聚类分析获得不同类别的样本子集，针对不同类别的样本子集建立不同的 SVM 模型，排除了不同类别数据建模对模型预测精度带来的影响。

3) 本文提出的 Kmeans-SVM 预测模型在晴天、多云情况下的预测精度较高，雨天的预测精度有了明显提高，具有一定的实用价值。

参考文献

- [1] 韩柳, 庄博, 吴耀武, 等. 风光水火联合运行电网的电源出力特性及相关性研究[J]. 电力系统保护与控制, 2016, 44(19): 91-98.
HAN Liu, ZHUANG Bo, WU Yaowu, et al. Power source's output characteristics and relevance in wind-solar-hydro-thermal power system[J]. Power System Protection and Control, 2016, 44(19): 91-98.
- [2] 黄伟, 张田, 韩湘荣, 等. 影响光伏发电的日照强度时间函数和气象因素[J]. 电网技术, 2014, 38(10): 2789-2793.
HUANG Wei, ZHANG Tian, HAN Xiangrong, et al.

- Sunlight intensity time function and weather factors influencing photovoltaic generation[J]. Power System Technology, 2014, 38(10): 2789-2793.
- [3] 张雪莉, 刘其辉, 马会萌, 等. 光伏电站输出功率影响因素分析[J]. 电网与清洁能源, 2012, 28(5): 75-81.
ZHANG Xueli, LIU Qihui, MA Huimeng, et al. Analysis of influencing factors of output power of photovoltaic power plant[J]. Power System and Clean Energy, 2012, 28(5): 75-81.
- [4] 王洪坤, 葛磊蛟, 李宏伟, 等. 分布式光伏发电的特性分析与预测方法综述[J]. 电力建设, 2017, 38(7): 1-9.
WANG Hongkun, GE Leijiao, LI Hongwei, et al. Review of characteristic analysis and prediction methods of distributed photovoltaic power generation[J]. Electric Power Construction, 2017, 38(7): 1-9.
- [5] 王要强, 王思谨, 蒋建东, 等. 光伏发电系统输出功率特性分析及其平滑控制研究[J]. 太阳能学报, 2016, 37(4): 847-852.
WANG Yaoqiang, WANG Sijin, JIANG Jiandong, et al. Analysis of output power characteristics and smoothing control of photovoltaic power generation system[J]. Acta Energiae Solaris Sinica, 2016, 37(4): 847-852.
- [6] MELLIT A, PAVAN A M, LUGHI V. Short-term forecasting of power production in a large-scale photovoltaic plant[J]. Solar Energy, 2014, 105: 401-413.
- [7] ALFREDO FERNANDEZ-JIMENEZ L, MUÑOZ-JIMENEZ A, FALCES A, et al. Short-term power forecasting system for photovoltaic plants[J]. Renewable Energy, 2012, 44: 311-317.
- [8] PIERRO M, BUCCIF, DE FELICE M, et al. Multi-model ensemble for day ahead prediction of photovoltaic power generation[J]. Solar Energy, 2016, 134: 132-146.
- [9] 张玉, 黄睿, 张振涛, 等. 基于克里格模型的光伏发电量预测[J]. 热力发电, 2017, 46(4): 27-32.
ZHANG Yu, HUANG Rui, ZHANG Zhentao, et al. Photovoltaic power generation prediction based on Kriging model[J]. Thermal Power Generation, 2017, 46(4): 27-32.
- [10] 傅美平, 马红伟, 毛建容. 基于相似日和最小二乘支持向量机的光伏发电短期预测[J]. 电力系统保护与控制, 2012, 40(16): 65-69.
FU Meiping, MA Hongwei, MAO Jianrong. Short-term photovoltaic power forecasting based on similar days and least square support vector machine[J]. Power System Protection and Control, 2012, 40(16): 65-69.
- [11] 张华彬, 杨明玉. 基于天气类型聚类和 LS-SVM 的光伏出力预测[J]. 电力科学与工程, 2014, 30(10): 42-47.
ZHANG Huabin, YANG Mingyu. Prediction of photovoltaic power output based on weather type clustering and LS-SVM[J]. Electric Power Science and Engineering, 2014, 30(10): 42-47.
- [12] 卢舟鑫, 王冰, 荣军峰. 基于多时段综合相似日的光伏发电功率预测[J]. 电源技术, 2017, 41(1): 103-106.
LU Zhouxin, WANG Bing, RONG Junfeng. Photovoltaic generation power prediction based on multi-period integrated similar days[J]. Chinese Journal of Power Sources, 2017, 41(1): 103-106.
- [13] 王新普, 周想凌, 邢杰, 等. 一种基于改进灰色 BP 神经网络组合的光伏出力预测方法[J]. 电力系统保护与控制, 2016, 44(18): 81-87.
WANG Xinpu, ZHOU Xiangling, XING Jie, et al. A prediction method of PV output power based on the combination of improved grey back propagation neural network[J]. Power System Protection and Control, 2016, 44(18): 81-87.
- [14] 王振旗, 姚晓斌. 基于 GA-BP 算法的光伏系统发电功率预测[J]. 计算机系统应用, 2016, 25(2): 227-230.
WANG Zhenqi, YAO Xiaobin. Generation power forecasting for photovoltaic system based on GA-BP[J]. Computer Systems & Applications, 2016, 25(2): 227-230.
- [15] 张玉, 莫寒, 张烈平. 基于模糊支持向量机的光伏发电量预测[J]. 热力发电, 2017, 46(1): 116-120.
ZHANG Yu, MO Han, ZHANG Lieping. Photovoltaic power prediction based on fuzzy support vector machine[J]. Thermal Power Generation, 2017, 46(1): 116-120.
- [16] ESEYE A T, ZHANG Jianhua, ZHENG Dehua. Short-term photovoltaic solar power forecasting using a hybrid wavelet-PSO-SVM model based on SCADA and meteorological information[J]. Renewable Energy, 2018, 118: 357-367.
- [17] 许童羽, 马艺铭, 曹英丽, 等. 基于主成分分析和遗传优化 BP 神经网络的光伏输出功率短期预测[J]. 电力系统保护与控制, 2016, 44(22): 90-95.
XU Tongyu, MA Yiming, CAO Yingli, et al. Short term forecasting of photovoltaic output power based on principal component analysis and genetic optimization of BP neural network[J]. Power System Protection and Control, 2016, 44(22): 90-95.
- [18] DABRA V, PALIWAL K K, SHARMA P, et al. Optimization of photovoltaic power system: a comparative study[J]. Protection and Control of Modern Power Systems, 2017, 2(2): 29-39. DOI: 10.1186/s41601-017-

- 0036-2.
- [19] LEVA S, DOLARA A, GRIMACCIA F, et al. Analysis and validation of 24 hours ahead neural network forecasting of photovoltaic output power[J]. Mathematics and Computers in Simulation, 2017, 131: 88-100.
- [20] 姚仲敏, 潘飞, 沈玉会, 等. 基于 GA-BP 和 POS-BP 神经网络的光伏电站出力短期预测[J]. 电力系统保护与控制, 2015, 43(20): 83-89.
- YAO Zhongmin, PAN Fei, SHEN Yuhui, et al. Short-term prediction of photovoltaic power generation output based on GA-BP and POS-BP neural network[J]. Power System Protection and Control, 2015, 43(20): 83-89.
- [21] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016.
- [22] 徐慧, 刘翔, 方策, 等. 一种基于可拓距的特征变换方法及其在网络入侵检测中的应用[J]. 河南师范大学学报(自然科学版), 2017, 45(5): 101-107.
- XU Hui, LIU Xiang, FANG Ce, et al. A feature transformation method based on extension distance and its application in network intrusion detection[J]. Journal of Henan Normal University (Natural Science Edition), 2017, 45(5): 101-107.
- [23] VAPNIK V N. The nature of statistical learning theory[M]. New York: Springer-Verlag, 1995.
- [24] 刘倩, 崔晨, 周杭霞. 改进型 SVM 多类分类算法在无线传感器网络中的应用[J]. 中国计量学院学报, 2013, 24(3): 298-303.
- LIU Qian, CUI Chen, ZHOU Hangxia. Application of a modified SVM multi-class classification algorithm in wireless sensor networks[J]. Journal of China Jiliang University, 2013, 24(3): 298-303.
- [25] 刘尚旺, 段德全, 崔艳萌, 等. 二次定位车牌分割及识别方法[J]. 河南师范大学学报(自然科学版), 2016, 44(4): 151-156.
- LIU Shangwang, DUAN Dequan, CUI Yanmeng, et al. Vehicle license plate segmentation and recognition method based on two time locations[J]. Journal of Henan Normal University (Natural Science Edition), 2016, 44(4): 151-156.

收稿日期: 2017-10-27; 修回日期: 2018-02-01

作者简介:

张雨金(1994—), 男, 硕士研究生, 研究方向为机器学习, 智能电网; E-mail: 1640398082@qq.com

杨凌帆(1995—), 男, 硕士研究生, 研究方向为智能电网、新能源并网; E-mail: 441848245@qq.com

葛双治(1994—), 男, 硕士研究生, 研究方向为数据挖掘、新能源并网。E-mail: 351761206@qq.com

(编辑 周金梅)